1.大语言模型是以Transformer为架构，使用大量文本数据训练的自回归的文本生成模型，大模型已经从最开始的聊天机器人到现在具备了一定的工具属性，能通过harness辅助或独立完成一些工作，且还在飞速进化中。大模型的大体现在他的规模上，训练成本、训练数据量、模型参数等等，通过庞大的训练数据和巨大的参数量，模型才在训练中“学习”到了强大的能力。

2.广义上看是的，从狭义上看，我们每天使用deepseek、豆包这些app实际上是大模型上套上一个框架（系统提示词、模式开关、联网搜索工具等）而得到的ai产品，应该看作一个简单的智能体。

3.token是大模型处理文本的最小单位，在大模型底层的Transformer架构中做自注意力时，模型做矩阵乘法计算时以矩阵乘法为单位，每次推理的成本因上下文的token数升高而升高，因此现在大模型都以token计费。

4.tokenizer，即分词器，是根据一套算法和一个词表将输入的原始文本切分为一个一个token的工具，如GPT使用的BPE算法，就是把每个字符都作为一个token，并将频繁出现在一起的token合并成一个新的token。

5.embedding是将每个token由id转换为一个多维向量的过程，两个token对应的向量的距离可以用于表示两个token的语义相近程度。

6.之前招新训练的模型都是为了某个具体任务训练出来的模型，而大模型则是由大量训练数据训练出来的通用语言模型，通用性更高，能力更强，且可以继续经过后训练得到特定领域的特化模型。

7.Transformer是大模型的底层架构，采用注意力机制实现token与token之间的联系，Encoder编码器是做的是不加掩膜的自注意力，做自注意力的时候模型可以看到整个句子，更适合用于训练模型“理解”文本，而Encoder解码器在做自注意力时只能看到前面的token，无法看到后面的token，更适合用于生成文本，如Decoder-only的nanoGPT，Encoder和Decoder做交叉注意力则适合去做翻译类任务，如《Attention is all you need》中所进行的任务。

8.架构层面，Transformer以注意力机制为核心，计算一段话中任意两个token的联系，并通过不同的注意力计算方法分为Encoder和Decoder两种来实现不同类型的任务。

9.

①DeepSeek系列，优势在于在保持较优秀的性能的情况下用优秀的架构达成极低的价格和极高的缓存命中率，不仅开放模型权重，还开放了算子库以及自家的推理框架DeepInfer。

②GPT系列，模型性能一直处在最前沿水平，从GPT-3开始从开源转换为闭源，可以在网页端使用chat、work模式，也能在codex内编码。

③Gemini系列，模型的编码能力不是顶尖水平，但是背靠谷歌的搜索引擎，Gemini的文字能力和世界知识非常丰富，没有开放过模型权重。

10.下游任务是指在预训练模型的基础上对某个垂直领域的特定任务进行微调的任务，与“预训练任务”相对。Backbone代表了大模型推理中将输入的token计算后转化为向量表示的过程，任务头则是根据具体任务的不同将Backbone的输出结果转化为任务需要的输出的过程。

附加题

1.模型的参数是模型中每层可训练的数值，模型训练或推理时所需要的显存不仅包含模型的参数，还包含计算图上累计的梯度、优化器中记录的信息等。计算模型的参数量可以看模型的每一层，计算可以训练的参数的数量并累加，计算显存时不仅要看模型参数量，还要看优化器的类型、计算的精度等综合计算。

2.计算精度就是模型训练时数字保留的有效位数，计算精度越高，模型计算时的准确性越高，但是训练所需要的空间也更大、训练时间更长。一般来说，训练更追求稳定度合数据的准确性，需要用更高的计算精度，推理时则要求快，使用更低的计算精度。

3.Agent是大模型和harness组合得到的可以执行任务的系统，大模型负责思考和决策，harness负责给大模型提供工具、管理上下文以及控制大模型的循环，因为大模型本身是无法与外界环节进行交互的，因此做出一个操作或者决策后他不知道这个行为的结果如何，因此才需要harness来提供反馈并推动进程，大模型和harness合起来就是一个智能体（Agent）。